



EACH

ACH2118 Introdução ao Processamento de Língua Natural

Exercício prático 1

Ivandr  Paraboni
EACH - USP

Tarefa

Em sistemas públicos de resposta a requisições do cidadão (e-SIC), deseja-se classificar automaticamente a clareza da resposta que foi fornecida ao usuário.

Para isso, é disponibilizado um corpus de treino (train.xlsx) de respostas rotuladas em 3 categorias pelos próprios usuários em uma escala 1..5, em que os escores intermediários são agregados em uma classe única.

	A	B
1	resp_text	clarity
2		c5
3		c1
4		c1
5		c234

A tarefa a ser resolvida é uma classificação ternária $\{c1, c234, c5\}$, rotulando o conjunto de texto de testes (sem rótulos) também fornecido.

Treino e teste

Cj. de treino

	A	B
1	resp_text	clarity
2		c5
3		c1
4		c1
5		c234
-		...

Modelo treinado



Rotulação do cj. teste

	A	B
1	resp_text	clarity
2		
3		
4		
5		
-		

O que fazer

- Use os conjuntos de treino e teste não rotulado para desenvolver um modelo de classificação superior a um baseline tradicional do tipo regressão logística com contagens TF-IDF.
 - Com penalidade para desempenho inferior ao *baseline*.
- Use o modelo para obter os rótulos de teste.

O que entregar

Entrega por um único membro de cada grupo até domingo 04/10 de 3 itens em uma pasta zipada (.zip):

1. **Relatório** do projeto conforme modelo disponibilizado
2. **Apresentação** em formato pdf (não ppt/pptx) com duração de até 10min.
3. Planilha do **conjunto de teste rotulado**.

Grupos: https://docs.google.com/spreadsheets/d/146sskIR6dNVHaOkIM4VM1XCbTdND7IS5LIX-x5X_LMw/edit?usp=sharing

O que será avaliado

Nota-base: acurácia média de teste (70%), método inovador / bem elaborado (20%), relatório (5%), apresentação em aula (5%).

Modelos de Tf-Idf/BoW com regressão logística, SVM, Naive Bayes e afins não pontuam no critério “inovação”.

(-) penalidades previstas

Como será avaliado

- A nota-base é normalizada pelo *ranking* global da turma (eg, o melhor resultado é atribuído nota dez etc.). Este *ranking* determina a ordem de apresentação dos trabalhos.
- Finalmente, são aplicadas as penalidades (problemas de entrega etc.) previstas de forma cumulativa, resultando na nota final do EP.

O que será penalizado

- **Baixo desempenho**: EPs cuja acurácia média seja inferior à média do *baseline* de classe majoritária recebem nota 3,0 e não são avaliados, e também não qualificam para o critério 'inovação'.
- **Descontos** de 20% aplicado a cada um dos casos a seguir, de forma cumulativa:
 - Resultado inferior ao baseline oficial (regressão logística + TF-IDF);
 - Não entregar de relatório ou código no prazo;
 - Não entregar do PDF da apresentação;
 - Formato inválido do arquivo de teste (e.g., mais/menos linhas ou colunas), ou rótulos diferentes/ fora da posição, tipo de arquivo não xlsx etc.

O que será valorizado

- Desistências e desaparecimentos podem, opcionalmente, ser indicados no relatório.
- Bônus de 10% na nota final para cada integrante “perdido”.
- Objetivo é valorizar grupos que tiveram que trabalhar mais.

Cronograma

- Entrega (resultado + apresentação + relatório com código) até domingo 04/10.
- Apresentação dos trabalhos em aula em 06/10 e 13/10 em ordem de resultado de acurácia do teste – começando pelo último colocado.
- Ausência na hora da apresentação anula a nota da apresentação (mas não do trabalho como um todo, desde que atenda aos demais critérios)

Avaliação dos resultados

- É possível que haja alguma queda de desempenho entre treinamento e teste
- Mas uma diferença muito grande indica *overfitting*, e que portanto o modelo não funciona
- Um resultado espetacular no treinamento, que depois cai drasticamente, não é um resultado real
- Como se proteger disso?
 - Pensando muito bem em quais características modelar
 - Realizando um grande número de testes com muitos parâmetros, algoritmos, representações etc. usando muito *grid search*
 - Realizando validação cruzada

O que é esperado desta tarefa

- Construir sua própria infraestrutura de desenvolvimento, e um pipeline robusto de experimentação (pensando no EP-2!)
- Resultados satisfatórios em relação ao baseline, e com pouco ou nenhum *overfitting*
- Despertar para as dificuldades práticas de modelar problemas de PLN usando aprendizado supervisionado
 - Em um problema simples, com dados balanceados e em pequeno volume
- Apresentação satisfatória do trabalho realizado na forma escrita e oral

Dicas finais

- Comece **simples**: garanta algum resultado por meio de um método rápido antes de se comprometer com soluções mais sofisticadas
- Não subestime o **tempo de treino**: mesmo os algoritmos mais simples podem consumir muito tempo de treino, especialmente quando usando *grid search* (altamente recomendado).
- Confira a entrega para se certificar de que **não faltou nada** do que foi pedido
- Ocupe **todos os integrantes do grupo** para que o trabalho se torne viável.

Bom trabalho!